Airflow is a platform to programmatically author, schedule and monitor workflows.



Nombre del alumno: José Ulises Vallejo Sierra

Código: 219747905

Sección: D06

Curso: Computación Tolerante a Fallas

Nombre del profesor: Michel Emanuel López Franco

Realizar un programa que sea capaz de revisar el estatus de tu aplicación. Técnica a utilizar: Airflow

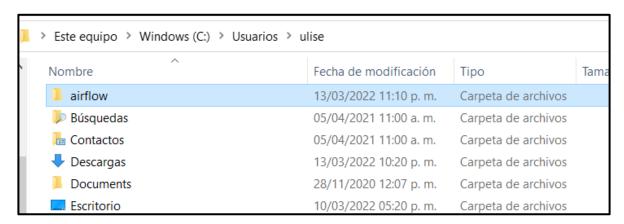
En esta ocasión se nos plantea un tema actual y novedoso que promete ser solución a diversos problemas o fallas en la computación y es una rama de la ingeniería que apoya a la tolerancia de estas fallas para mitigar los problemas presentados en las aplicaciones, se trata de la gestión de el flujo de trabajo, y en esta ocasión específicamente con la utilización del módulo airflow que nos ayudará precisamente con este rubro en el lenguaje Python, cabe destacar que apache airflow no está definido para Windows, por lo que se requiere de un interprete de Linux que nos facilitará su implementación.

Programa: Creación de una DAG

Usaremos Airflow para completar una tarea relativamente simple hoy: imprimir un mensaje de hola mundo para comprobar que la tarea se haya creado y sea capaz de visualizarse en el localhost:8080 de nuestras DAGs.

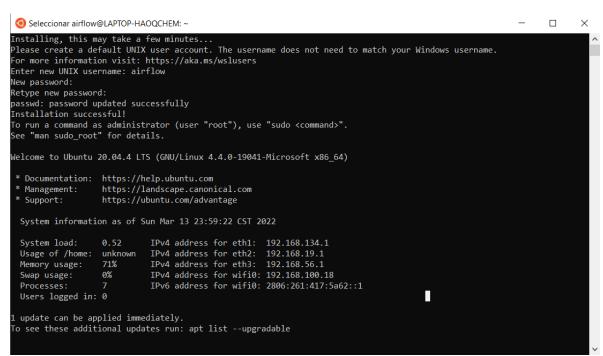
Para la instalación del subsistema de linux para windows, abrimos el powershell y ejecutamos el siguiente comando como administrador.

Posteriormente creamos la carpeta airflow en la unidad C: / Usuarios / ulise para alojar los dags a crear con el airflow



Descargamos en Microsoft Store Ubuntu que servirá como distribución de Linux para Windows.

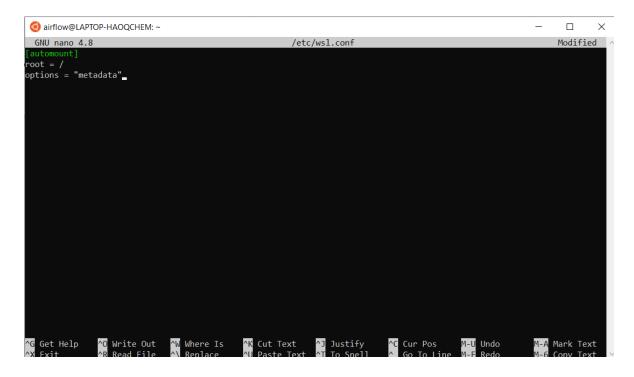




Para asegurarnos de que todos los componentes de Ubuntu estén actualizados ejecutamos el siguiente comando

```
sirflow@LAPTOP-OM375MPI:-$ sudo apt update && sudo apt upgrade
[sudo] password for airflow:
Set:1 http://security.ubuntu.com/ubuntu focal-security InRelease [114 k8]
Hit:2 http://archive.ubuntu.com/ubuntu focal InRelease
Set:3 http://archive.ubuntu.com/ubuntu focal-updates InRelease [114 k8]
Set:4 http://archive.ubuntu.com/ubuntu focal-backports InRelease [108 k8]
Set:5 http://security.ubuntu.com/ubuntu focal-security/main amd64 Packages [1317 k8]
Set:6 http://archive.ubuntu.com/ubuntu focal/universe amd64 Packages [8628 k8]
Set:7 http://security.ubuntu.com/ubuntu focal-security/main Translation-en [231 k8]
Set:8 http://security.ubuntu.com/ubuntu focal-security/restricted amd64 Packages [799 k8]
Set:10 http://security.ubuntu.com/ubuntu focal-security/restricted Translation-en [114 k8]
Set:11 http://security.ubuntu.com/ubuntu focal-security/universe amd64 Packages [692 k8]
Set:12 http://security.ubuntu.com/ubuntu focal-security/universe Translation-en [121 k8]
Set:13 http://security.ubuntu.com/ubuntu focal-security/universe amd64 c-n-f Metadata [14.0 k8]
```

Abrimos el sudo nano /etc/wsl/.conf para ajustar con el editor nano para anular la configuración de montaje y poder trabajar por lo que escribimos las siguientes tres líneas de código.



Corroboramos nuestra versión de Python y ejecutamos el comando sudo apt update para asegurarnos de que todo se mantenga actualizado.

```
airflow@LAPTOP-HAOQCHEM:~$ python3 --version

Python 3.8.10

airflow@LAPTOP-HAOQCHEM:~$ sudo apt update

[sudo] password for airflow:

Get:1 http://security.ubuntu.com/ubuntu focal-security InRelease [114 kB]

Hit:2 http://archive.ubuntu.com/ubuntu focal InRelease

Get:3 http://archive.ubuntu.com/ubuntu focal-updates InRelease [114 kB]

Get:4 http://archive.ubuntu.com/ubuntu focal-backports InRelease [108 kB]

Fetched 336 kB in 5s (72.8 kB/s)

Reading package lists... Done

Building dependency tree

Reading state information... Done

All packages are up to date.

airflow@LAPTOP-HAOQCHEM:~$ ___
```

Instalación el gestor de paquetes de Python3 "pip".

```
airflow@LAPTOP-HAOQCHEM:~$ sudo apt install python3-pip

Reading package lists... Done

Building dependency tree

Reading state information... Done

The following package was automatically installed and is no longer required:
    libfwupdplugin1

Use 'sudo apt autoremove' to remove it.

The following additional packages will be installed:
    binutils binutils-common binutils-x86-64-linux-gnu build-essential cpp cpp-9 dpkg-dev fakeroot g++ g++-9 gcc gcc-9
    gcc-9-base libalgorithm-diff-perl libalgorithm-diff-xs-perl libalgorithm-merge-perl libasan5 libatomic1 libbinutils
    libc-dev-bin libc6-dev libcc1-0 libcrypt-dev libctf-nobfd0 libctf0 libdpkg-perl libexpat1-dev libfakeroot
    libfile-fcntllock-perl libgcc-9-dev libgomp1 libis122 libitm1 liblsan0 libmpc3 libpython3-dev libpython3.8-dev
    libquadmath0 libstdc++-9-dev libtsan0 libubsan1 linux-libc-dev make manpages-dev python-pip-whl python3-dev
    python3-wheel python3.8-dev zlib1g-dev

Suggested packages:
```

Instalamos apache-airflow con los parámetros determinados para nuestro contexto

```
QLAPTOP-HAOQCHEM:~$ pip3 install apache-airflow[gcp,statsd,sentry]==1.10.10
Collecting apache-airflow[gcp,sentry,statsd]==1.10.10
 Downloading apache_airflow-1.10.10-py2.py3-none-any.whl (4.7 MB)
                                      4.7 MB 2.1 MB/s
Collecting iso8601>=0.1.12
 Downloading iso8601-1.0.2-py3-none-any.whl (9.7 kB)
Collecting text-unidecode==1.2
 Downloading text_unidecode-1.2-py2.py3-none-any.whl (77 kB)
                                     77 kB 4.9 MB/s
Collecting lazy-object-proxy~=1.3
 Downloading lazy_object_proxy-1.7.1-cp38-cp38-manylinux_2_5_x86_64.manylinux1_x86
14_x86_64.whl (60 kB)
                                      60 kB 3.6 MB/s
Collecting pandas<1.0.0,>=0.17.1
 Downloading pandas-0.25.3-cp38-cp38-manylinux1_x86_64.whl (10.4 MB)
                                      10.4 MB 75 kB/s
Collecting python-dateutil<3,>=2.3
 Downloading python_dateutil-2.8.2-py2.py3-none-any.whl (247 kB)
                                     247 kB 6.0 MB/s
Collecting future<0.19,>=0.16.0
```

Además, instalamos dos módulos que necesitamos para el pip

Exportamos la ruta de la carpeta que creamos en el segundo paso tanto en el Ubuntu con el comando export como en el bash con el comando nano~/.bashrc para agregar las variables de entorno y reiniciamos.

airflow@LAPTOP-HAOQCHEM:~\$ export AIRFLOW HOME=/c/Users/ulise/airflow

```
airflow@LAPTOP-HAOQCHEM: ~
                                                                                                           Modified ^
  ~/.bashrc: executed by bash(1) for non-login shells
 see /usr/share/doc/bash/examples/startup-files (in the package bash-doc)
 for examples
 xport AIRFLOW_HOME=/c/Users/ulise/airflow_
 If not running interactively, don't do anything
# don't put duplicate lines or lines starting with space in the history.
 See bash(1) for more options
HISTCONTROL=ignoreboth
# append to the history file, don't overwrite it
shopt -s histappend
HISTSIZE=1000
HISTFILESIZE=2000
shopt -s checkwinsize
              ^K Cut Text
                                                         ^J Justify
                                                                        ^C Cur Pos
                                                                                                     M-A Mark Text
^G Get Help
^X Exit
```

Ahora comprobamos nuestra versión de airflow y vemos que no arroje errores

```
airflow@LAPTOP-HAOQCHEM:~$ airflow version 1.10.10
```

Inicializamos la base de datos de nuestra versión de airflow con este comando

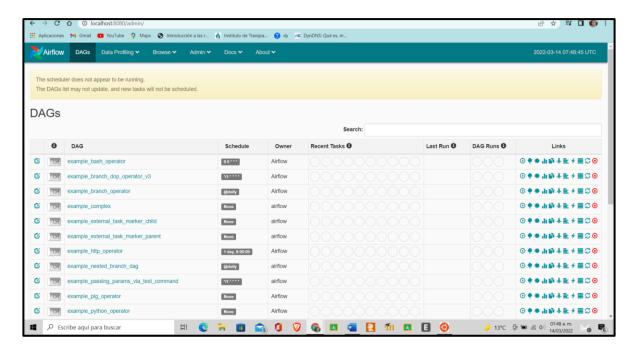
```
airflow@LAPTOP-HAOQCHEM:~$ airflow initdb
DB: sqlite:///c/Users/ulise/airflow/airflow.db
[2022-03-14 01:45:01,569] {db.py:378} INFO - Creating tables
INFO [alembic.runtime.migration] Context impl SQLiteImpl.
INFO [alembic.runtime.migration] Will assume non-transactional DDL.
INFO [alembic.runtime.migration] Running upgrade -> e3a246e0dc1, current schema
INFO [alembic.runtime.migration] Running upgrade -> e3a246e0dc1 -> 1507a7289a2f, create is_encrypted
/home/airflow/.local/lib/python3.8/site-packages/alembic/ddl/sqlite.py:74: UserWarning: Skipping unsupported ALTER for
reation of implicit constraint. Please refer to the batch mode feature which allows for SQLite migrations using a copy-
nd-move strategy.

util.warn(
INFO [alembic.runtime.migration] Running upgrade 1507a7289a2f -> 13eb55f81627, maintain history for compatibility with
earlier migrations
INFO [alembic.runtime.migration] Running upgrade 13eb55f81627 -> 338e90f54d61, More logging into task_instance
INFO [alembic.runtime.migration] Running upgrade 338e90f54d61 -> 52d714495f0, job_id indices
INFO [alembic.runtime.migration] Running upgrade 5024714495f0 -> 502898887f84, Adding extra to Log
INFO [alembic.runtime.migration] Running upgrade 502898887f84 -> 1538cef5b76e, add dagrun
INFO [alembic.runtime.migration] Running upgrade 1538cef5b76e -> 2e541a1dcfed, task_duration
INFO [alembic.runtime.migration] Running upgrade 2641a1dcfed -> 40e67319e3a9, dagrun config
INFO [alembic.runtime.migration] Running upgrade 40e67319e3a9 -> 561833c1c74b, add password column to user
INFO [alembic.runtime.migration] Running upgrade 40e67319e3a9 -> 561833c1c74b, add password column to sla_miss
INFO [alembic.runtime.migration] Running upgrade 561833c1c74b -> 4446e08588, dagrun start end
INFO [alembic.runtime.migration] Running upgrade 561833c1c74b -> 4446e08588, dagrun start end
INFO [alembic.runtime.migration] Running upgrade 561833c1c74b -> 4446e08588, dagrun start end
INFO [alembic.runtime.migration] Running upgrade 561835c1c74b -> 4446e08588, dagrun start end
INFO [alem
```

Corremos el apache airflow con el comando airflow webserver para ejecutar el servidor en localhost:8080 y en otra ventana ejecutamos el comando aiflow scheduler



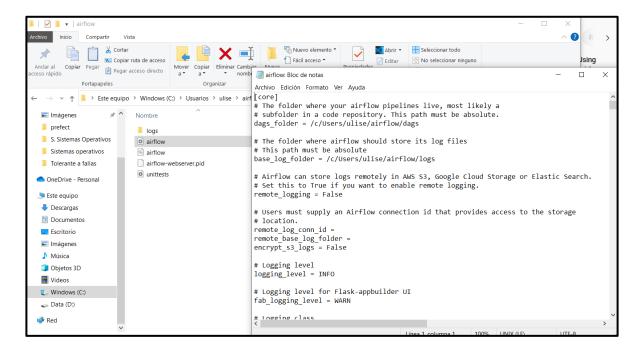
Como observamos, en el browser ya se ejecuta normalmente el servidor con las dags de ejemplo, pero nos salta la advertencia o error de Schedule ya que aun no lo hemos implementado



Como observamos en la siguiente imagen, al ejecutar el Scheduler nos arroja algunos errores los cuales se solucionan de la siguiente manera

```
airflow@LAPTOP-HAOQCHEM: ~
                                                                                                                                X
   low@LAPTOP-HAOQCHEM:~$ airflow schedule
                            {_init_.py:51} INFO - Using executor SequentialExecutor {scheduler_job.py:1346} INFO - Starting the scheduler
                            {scheduler_job.py:1354} INFO - Running execute loop for -1 seconds
                                          job.py:1355} INFO - Processing each file at most -1 times
                            {scheduler_job.py:1358} INFO - Searching for files in /c/Users/ulise/airflow/dags {scheduler_job.py:1360} INFO - There are 24 files in /c/Users/ulise/airflow/dags
                             {scheduler_job.py:1411} INFO - Resetting orphaned tasks for active dag runs
                                                  (:556} INFO - Launched DagFileProcessorManager with pid: 208
                            {settings.py:54} INFO - Configured default timezone <Timezone [UTC]>
2022-03-14 01:52:02,889] {dag_processing.py:756} WARNING - Because we cannot use more than 1 thread (max_threads = 2)
en using sqlite. So we set parallelism to 1.
Process DagFileProcessor0-Process:
raceback (most recent call last):
 File \ "/usr/lib/python 3.8/multiprocessing/process.py", \ line \ 315, \ in \ \_bootstrap
   self.run()
 File "/usr/lib/python3.8/multiprocessing/process.py", line 108, in run
```

Abrimos con ayuda de bloc de notas dentro de nuestra carpeta de Airflow el archivo airflow con extensión cfg



Buscamos la línea load_examples y cambiamos el valor de verdadero a falso, guardamos cambios y volvemos a ejecutar el servidor con airflow webserver y airflow scheduler

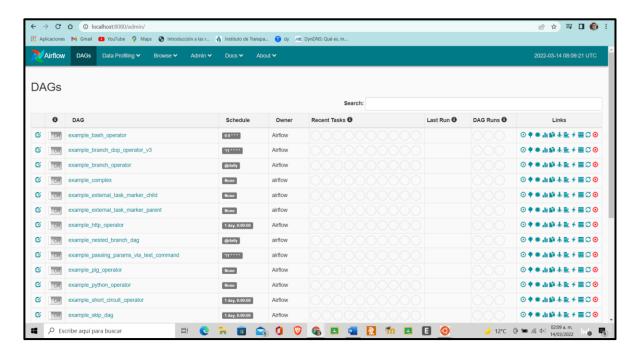
```
# Are DAGs paused by default at creation
dags_are_paused_at_creation = True

# The maximum number of active DAG runs per DAG
max_active_runs_per_dag = 16

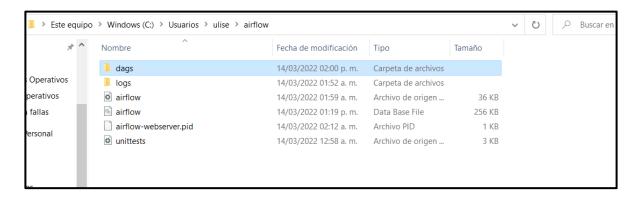
# Whether to load the DAG examples that ship with Airflow. It's good to
# get started, but you probably want to set this to False in a production
# environment
load_examples = False
```

Como se observa ya se ejecuta con éxito el comando airflow scheduler

Miramos en nuestro browser localhost:8080 que ya no salte el error de scheduler



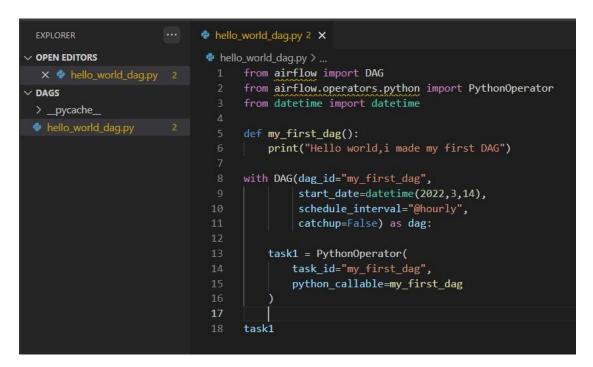
Ahora creamos dentro de la carpeta airflow una carpeta para los dags que vamos a crear y la abrimos con el intérprete de visual studio



Creamos nuestra dag, importando las librerías necesarias para que funcione el airflow además de una librería de datatime para para agendar las tareas en un tiempo definido y ejecutamos nuestra función para la dag, la cual imprimirá el mensaje de hola mundo y se visualizará en nuestro browser.

En nuestro constructor de la DAG pasamos los argumentos id, la fecha de inicio y el intervalo de ejecución, además del parámetro de nuestra task por medio de PythonOperator.

Finalmente establecemos el flujo de ejecución para nuestra task1



Una vez definida la dag refrescamos nuestro browser en localhost:8080 y visualizamos que nuestra dag "my_first_dag" fue creada con éxito, además ejecutamos dicha dag en el botón de play y como se observa la corrida numero uno ha iniciado, coloreando el borde de verde.



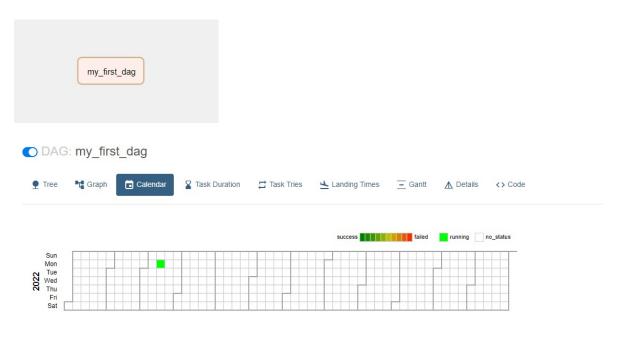
Ahora navegamos por la dag para ver sus grafos y detalles

José Ulises Vallejo Sierra

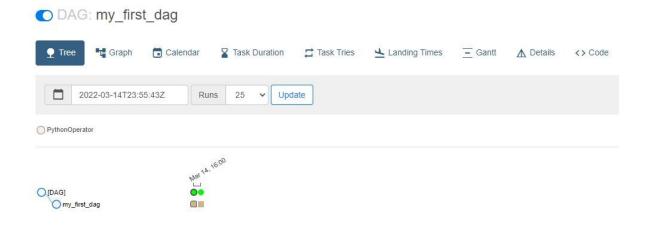
Computación Tolerante a Fallas



Visualizamos también el calendario de ejecución que nos marca el momento en el que la dag se puso en marcha, además vemos el grafo de un estado que arroja



Por último, visualizamos las dependencias de nuestras task dentro del dag en el gráfico de árbol, el cual también indica la fecha de ejecución



Conclusión

Al igual que el módulo Prefect visto anteriormente, Airflow nos ayuda a gestionar el flujo de trabajo de las tareas de un programa a ejecutar, esto con objetivo de mitigar los errores que puedan llegar a presentarse, ya que al crear la canalización de dependencia entre tareas, seccionamos bien cada uno de los procesos y evitamos que un error pueda afectar subprocesos dependientes, la idea de apache airflow es crear una interfaz con la que puedas crear, visualizar y gestionar dichos flujos de trabajo de "dags" definidas mediante scripts de Python, en mi caso, la visualización del flujo de trabajo de un script que manda un mensaje de hola mundo; esto con la finalidad de crear trabajos más complejos y que nos den la libertad de personalizar nuestros procesos sin limitaciones como las canalizaciones etl de prefect.

En pocas palabras, este nuevo módulo Airflow permite la administración de las tareas visualizando su dependencia, flujo y estado, y también permitiendo fallas exitosas de cada tarea en dicho flujo, lo cual es muy útil en la tolerancia de fallas, ya que una canalización de datos implementada con Airflow, al igual que Prefect ignorará el estado de la tarea y solamente se dedicará a transmitir los datos, esto con la finalidad de permitir usar el estado para tomar decisiones y permitir que tareas fallidas continúen con un flujo funcional.

Bibliografías

- datastacktv [datastacktv]. (2020, agosto 24). Install Apache Airflow on Windows using Windows Subsystem for Linux (WSL). Youtube. https://www.youtube.com/watch?v=M521KLHGaZc
- INSAID. (2021, agosto 18). Hello World using Apache-Airflow INSAID.
 Medium. https://insaid.medium.com/hello-world-using-apache-airflow-91859e3bbfd5
- Sanchez, C., Cabrero, R. J., Guerra, R. S. G., Cortes, D. B., López, R. G., & Roces, V. (2021, abril 7). Apache Airflow: Python como motor de orquestación de flujos de trabajo. Blog de Hiberus Tecnología.
 https://www.hiberus.com/crecemos-contigo/apache-airflow-python-como-motor-de-orquestacion-de-flujos-de-trabajo/

LINK AL REPOSITORIO:

https://github.com/UlisesVallejo/Airflow.git